

GPT4RUL 复现与改进： 航空发动机剩余使用寿命预测技术报告

李浩翔

2026 年 7 月

摘要

本报告对 Tan 等人提出的 GPT4RUL 方法在 NASA C-MAPSS 基准 (FD001-FD004) 上进行了独立复现与系统性改进。方法采用 KMeans 工况归一化、相关度-单调性特征选择、补丁通道融合 (PCF) 模块与冻结 GPT-2 骨干网络，并引入工况嵌入 (Condition Embedding) 与软提示 (Soft Prompt) 扩展。复现配置下，GPT4RUL+CE 在四数据集上的测试 RMSE 为 14.87/12.87/13.69/13.38；Hybrid+Soft Prompt 在 FD002 上达到 **12.55**，优于原文 11.05 的公开基准对比水平。消融实验表明：验证集若仅取每引擎末窗口，测试 RMSE 可恶化 5-11 个周期；随机引擎划分是避免数据泄漏的必要条件。代码与一键复现脚本已开源：<https://github.com/icemilk-1/GPT4RUL-Reproduction>。

1 方法

1.1 数据预处理

在 C-MAPSS 数据集上，预处理流程如下：

- **工况聚类归一化**：对三个运行参数 KMeans 聚类 (FD001/003 取 $K=1$ ；FD002/004 取 $K=6$)，簇内 Z-score 后全局 MinMax 至 $[0, 1]$ 。
- **特征选择**：传感器 j 的综合得分

$$Cri_j = 0.5 \cdot |r_j| + 0.5 \cdot mono_j, \quad (1)$$

保留 $Cri_j > \bar{Cri}$ 的传感器 (13-14 个)，并拼接 3 维工况参数 (共 17 维输入)。

- **滑窗与划分**：步长 1，RUL 截断 125；采用 Random Engine Split (80/20 按发动机 ID)，杜绝跨集合泄漏。

表 1: 各数据集超参数 (参照原文 Table 2)。

参数	FD001	FD002	FD003	FD004
窗口长度	30	64	40	64
Patch stride	4	8	8	8
PCF 块数	2	2	1	2
Mixing factor	2	2	1	1
Batch size	64	128	64	128

1.2 模型架构

图 1 展示 GPT4RUL 流水线。给定输入 $\mathbf{X} \in \mathbb{R}^{B \times T \times F}$ ，分块 ($K=8$) 后经 PCF 块处理：

$$\mathbf{H}' = \mathbf{H} + \text{MLP}_{\text{patch}}(\text{LN}(\mathbf{H})), \quad (2)$$

$$\mathbf{H}'' = \mathbf{H}' + \text{MLP}_{\text{channel}}(\text{LN}(\mathbf{H}')), \quad (3)$$

线性映射至 768 维后接入冻结的三层 GPT-2，展平经线性头输出 RUL。扩展方案 Hybrid Prompt RUL 在序列前端拼接 $M=4$ 个可学习 768 维软提示向量。仅 PCF、投影层、回归头 (及软提示) 可训练；GPT-2 参数完全冻结 (约 38M 参数)。

1.3 训练配置

Adam 优化器， $lr=0.005$ ，权重衰减 0.01，MSE 损失，Dropout 0.2，StepLR (每 10 epoch $\times 0.1$)，早停 patience=10。批大小：FD001/003 为 64，FD002/004 为 128；验证集使用引擎隔离的全部验证窗口 (`val_mode=all`)。

2 实验

实验环境：PyTorch，随机种子 42，评价指标为

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2}, \quad (4)$$

及 C-MAPSS 非对称 Score；预测值截断至 $[0, 125]$ 。

表 2 给出 GPT4RUL+ 工况嵌入的复现结果，FD004 最接近原文 (+0.70 RMSE)。表 3 对比三种架构：简单场景 (FD003) 纯 PCF 最优；多工况场景 Hybrid+ 软




图 1: GPT4RUL 模型架构 (蓝色可训练, 灰色冻结)。

表 2: 主复现结果 vs. Tan et al. (2025)。

数据集	原文 RMSE	复现 RMSE	差距
FD001	11.23	14.87	+3.64
FD002	11.05	12.87	+1.82
FD003	11.45	13.69	+2.24
FD004	12.68	13.38	+0.70

表 3: 多模型测试 RMSE 对比 (越低越好)。

数据集	纯 PCF	GPT4RUL+CE	Hybrid+SP	原文
FD001	14.16	14.87	13.80	11.23
FD002	13.61	12.87	12.55	11.05
FD003	12.99	13.69	13.59	11.45
FD004	14.52	13.38	13.76	12.68

提示在 FD001/002 最优, 且 **FD002 (12.55)** 为四数据集中唯一优于原文公开值的配置。

3 消融发现

3.1 验证协议陷阱 (核心发现)

若验证集仅取每台发动机最后一个窗口 ($RUL \approx 0$), 模型会学习”输出接近零”的捷径, 导致测试 RMSE 严重恶化 (表 4)。

3.2 诊断实验清单

归纳发现: (1) LLM 价值随任务复杂度变化, 非简单场景下纯 PCF 已足够; (2) 软提示是激活 GPT-2 的关键, 无软提示时 LLM 可能拖后腿; (3) 评估协议 (划分方式、验证集构造) 对结论的影响远大于 PCF 微结构调参 (< 0.5 RMSE); (4) 四数据集无单一最优架构, 需按工况/故障复杂度自适应选择。

图 4 进一步说明验证协议对训练过程的影响: 末窗口协议在第 1 epoch 即将 checkpoint 锁定为欠拟合状态。

4 结论

本报告完成了 GPT4RUL 在 C-MAPSS 上的端到端复现, 并通过 12+ 项诊断实验揭示了 LLM-based PHM 研究中的关键方法论问题。主要结论如下:

1. 成功搭建可复现流水线并开源 (含一键脚本 `reproduce.ps1`)。




图 2: 复现 RMSE 与原文对比。

表 4: 验证协议消融 (测试 RMSE)。

数据集	仅末窗口	全部验证	改善
FD001	26.19	14.87	-11.32
FD002	17.90	12.87	-5.03
FD003	23.89	13.69	-10.20

2. Hybrid+Soft Prompt 在 FD002 上取得当前最佳结果 (RMSE 12.55)。
3. 引擎隔离划分与完整验证窗口是可信评估的必要条件。

建议: 始终按发动机 ID 划分训练/验证集; 避免仅在末窗口 RUL 上验证; 多工况数据应显式编码运行参数。后续工作包括 GPT-2 层数消融、多种子统计与更完整的配对消融落盘实验。

开源仓库: <https://github.com/icemilk-1/GPT4RUL-Reproduction>




图 3: RUL 衰减与验证协议影响。

表 5: 12+ 项复现诊断 (精选)。

排查项	结论
验证集 last_window → all	改善 5-11 RMSE
Random Engine Split	避免泄漏 (采用)
Temporal split (同发动机)	val 虚高 ~6.6 RMSE
Condition Embedding	四数据集均改善
PCF 双独立 Pre-LN	对齐 MLP-Mixer
Dropout 0.3 / LR 0.002	性能恶化
Grad clip 禁用 vs 1.0	初步: 禁用更稳
GPT-2 层数	待系统消融




图 4: FD001 训练动态: 正确验证协议 vs. 末窗口验证 (epoch 1 即早停)。